

Perbandingan Algoritma *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU) untuk Prediksi Indeks Harga Saham Gabungan (IHSG)

(Comparison of Long Short-Term Memory (LSTM) and Gated Recurrent Unit (GRU) for Jakarta Composite Indeks (JCI) Prediction)

ABSTRAK

Indeks Harga Saham Gabungan (IHSG) berperan sebagai indikator utama pasar modal Indonesia. Namun, sifatnya yang fluktuatif dan kompleks menyulitkan proses prediksi dengan metode tradisional. Penelitian ini bertujuan membandingkan performa dua arsitektur *deep learning*, yaitu *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU), dalam memprediksi IHSG menggunakan data historis dari tahun 2015 hingga 2025. Data diperoleh dari situs *investing.com*, kemudian dinormalisasi, dibagi menjadi data pelatihan dan pengujian, dan dilatih menggunakan berbagai kombinasi *hyperparameter*. Akurasi prediksi dievaluasi menggunakan *Mean Absolute Percentage Error* (MAPE). Hasil menunjukkan bahwa model GRU dengan konfigurasi *neuron* 32–32 dan *batch size* 32 menghasilkan MAPE terendah sebesar 1.68%, mengungguli LSTM dengan MAPE terbaik sebesar 1.81%. Dengan demikian, GRU terbukti lebih akurat dan efisien dalam memprediksi IHSG, serta menunjukkan potensi besar penerapan AI dalam statistik resmi dan perencanaan ekonomi nasional berbasis data.

Kata kunci: IHSG, *deep learning*, LSTM, GRU, prediksi saham

ABSTRACT

The Jakarta Composite Index (JCI) serves as a key indicator of Indonesia's capital market performance. However, its volatile and complex nature challenges traditional prediction methods. This study aims to compare the performance of two deep learning architectures, Long Short-Term Memory (LSTM) and Gated Recurrent Unit (GRU), in predicting the JCI using historical data from 2015 to 2025. Data were obtained from *investing.com*, normalized, split into training and testing sets, and trained using various hyperparameter configurations. Prediction accuracy was evaluated using the Mean Absolute Percentage Error (MAPE). Results show that the GRU model with a 32–32 neuron configuration and a batch size of 32 achieved the Lowest MAPE of 1.68%, outperforming the best LSTM model with a MAPE of 1.81%. Therefore, GRU demonstrates Higher accuracy and efficiency in predicting the JCI, Highlighting the significant potential of AI applications in official statistics and data-driven national economic planning.

Keywords: JCI, *deep learning*, LSTM, GRU, stock prediction

PENDAHULUAN

Pasar modal memainkan peran vital sebagai mesin penggerak pertumbuhan ekonomi nasional, terutama dalam era ekonomi digital yang serba cepat dan dinamis (Rohyati et al., 2024). Sebagai pusat transaksi surat berharga, pasar modal menjadi sarana penting dalam menghimpun dan mengalokasikan dana masyarakat secara produktif. Indikator Harga Saham Gabungan (IHSG) berperan sebagai indikator penting dalam mencerminkan kondisi dan performa pasar modal di Indonesia (Jannah et al., 2024). Indeks Harga Saham Gabungan (IHSG) merepresentasikan pergerakan keseluruhan harga saham di Bursa Efek Indonesia, sehingga berperan sebagai indikator utama dalam menilai keadaan makroekonomi, persepsi investor, serta dampak dari kebijakan fiskal dan moneter yang dijalankan oleh pemerintah (Esli Silalahi, 2021).

Dalam konteks ekonomi digital yang dinamis saat ini, kemampuan untuk memprediksi pergerakan IHSG menjadi semakin krusial, baik untuk investor, pelaku pasar, maupun lembaga pengambil kebijakan. Prediksi IHSG dapat membantu dalam manajemen risiko, pengambilan keputusan investasi, dan penyusunan strategi ekonomi nasional. Namun, sifat data IHSG yang sangat fluktuatif, nonlinier, dan dipengaruhi oleh berbagai faktor eksternal menjadikannya sulit untuk diprediksi dengan pendekatan metode statistika tradisional seperti regresi linier atau ARIMA (Liu, 2024).

Sebagai solusi atas keterbatasan model prediktif tradisional, teknologi *Artificial Intelligence* (AI), khususnya dalam bidang *deep learning*, telah mulai banyak digunakan dalam pemodelan data *time series* (Lara-Bentez et al., 2021). Dua jenis arsitektur yang umum digunakan dalam konteks ini adalah *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU), yang keduanya merupakan varian dari *Recurrent Neural Network* (RNN) (Shiri et al., 2024). Kedua model ini dirancang untuk mengatasi keterbatasan RNN biasa dalam menyimpan informasi jangka panjang dengan menggunakan mekanisme *gating system* (Waqas & Humphries, 2024).

Studi sebelumnya mengindikasikan bahwa kinerja *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU) dalam memprediksi data *time series* sangat dipengaruhi oleh sifat data serta konteks penerapannya. Studi oleh Putro et al. (2023) menunjukkan bahwa LSTM secara signifikan mengungguli *Linear Regression* (LR) dalam prediksi harga emas, dengan RMSE sebesar 19,095 dibandingkan 209.832 pada LR. Hasil serupa ditemukan oleh Sunendar et al. (2025), di mana LSTM mencatat MAPE terendah sebesar 10,76%, mengalahkan GRU (11,47%) dan ARIMA (11,23%) pada prediksi penjualan aerosol. Dalam prediksi volatilitas kurs, meskipun GRU menunjukkan konsistensi tinggi (92,39% nilai aktual dalam rentang 95% confidence interval), LSTM tetap mencatat RMSE terkecil yaitu 0,0000250 (Septani et al., 2025).

Namun, sejumlah penelitian lain menunjukkan hasil yang berbeda. Hariyanti et al. (2025) menunjukkan bahwa dalam prediksi harga saham BBKA, GRU menghasilkan prediksi yang lebih dekat ke nilai aktual, sementara LSTM hanya optimal pada konfigurasi tertentu (*batch size* 64, *epoch* 20) dengan MAE 158,51 dan MAPE 2,25%. Abbas et al. (2024) juga menegaskan keandalan GRU dalam pelatihan jangka panjang dan *batch* besar, meskipun LSTM lebih responsif pada data individu. Lebih lanjut, Marwondo & Hidayah (2022) menunjukkan bahwa GRU mengungguli LSTM dalam prediksi harga emas dunia (1968–2022) berdasarkan MSE, RMSE, dan MAE. Secara keseluruhan, LSTM kerap unggul secara numerik, tetapi GRU menawarkan efisiensi dan konsistensi yang kuat, terutama dalam konteks prediksi jangka panjang. Namun, studi yang secara khusus membandingkan keduanya dalam konteks prediksi IHSG masih terbatas, menandakan perlunya penelitian lanjutan yang lebih mendalam.

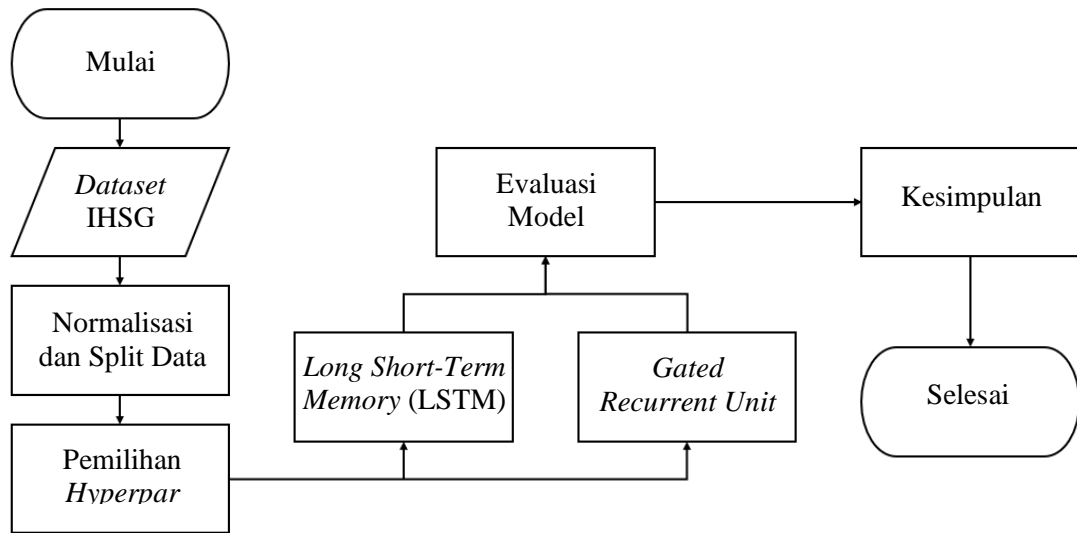
Sebagai bagian dari upaya mendukung penyediaan statistik resmi yang adaptif terhadap dinamika ekonomi digital, implementasi metode *deep learning* seperti LSTM dan GRU merepresentasikan pemanfaatan nyata sains data dan kecerdasan buatan (AI) dalam mendukung pembangunan berkelanjutan. Melalui prediksi Indeks Harga Saham Gabungan (IHSG) yang lebih akurat, penelitian ini diharapkan dapat berkontribusi dalam penyediaan indikator statistik yang lebih presisi, guna memperkuat ekosistem ekonomi digital yang tangguh dan kreatif.

Oleh karena itu, penelitian ini bertujuan untuk membandingkan performa model LSTM dan GRU dalam memprediksi IHSG berdasarkan data historis, dengan mengevaluasi akurasi menggunakan metrik MAPE. Hasil yang diperoleh diharapkan dapat menjadi kontribusi strategis dalam pengembangan sistem prediksi berbasis AI yang mendukung perencanaan ekonomi nasional yang berbasis data.

METODE

Alur Penelitian

Penelitian ini dilakukan melalui serangkaian tahapan yang tersusun secara sistematis, seperti yang diperlihatkan pada Gambar 1. Tahap pertama dilakukan dengan menghimpun data harga penutupan harian Indeks Harga Saham Gabungan (IHSG) yang diperoleh dari situs *investing.com*, mencakup rentang waktu mulai 1 Januari 2015 hingga 17 Mei 2025. Data yang diperoleh kemudian melalui proses normalisasi menggunakan teknik *min-max normalization*, sehingga nilainya berada dalam rentang 0 hingga 1. Setelah itu, data dibagi menjadi dua kelompok, yaitu 80% untuk pelatihan dan 20% sisanya untuk pengujian. Selanjutnya, dilakukan proses penentuan *hyperparameter* model melalui metode *trial and error* untuk menemukan konfigurasi terbaik. Dengan *hyperparameter* yang telah ditetapkan, pelatihan model dilakukan menggunakan dua algoritma: *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU). Kedua model dilatih dengan data *train* dan diuji menggunakan data *test*. Hasil dari prediksi masing-masing model kemudian dievaluasi menggunakan metrik *Mean Absolute Percentage Error* (MAPE) guna mengukur akurasi kinerja model. Tahapan terakhir dari penelitian ini adalah menyimpulkan temuan berdasarkan hasil evaluasi yang diperoleh.



Gambar 1. Alur Penelitian.

Data Penelitian

Penelitian ini memanfaatkan data historis harga penutupan harian Indeks Harga Saham Gabungan (IHSG) yang diambil dari situs *investing.com*. Data yang digunakan mencakup periode 2 Januari 2015 hingga 16 Mei 2025. Pemilihan IHSG sebagai fokus penelitian didasarkan pada fungsinya sebagai barometer utama yang menggambarkan performa keseluruhan pasar saham di Indonesia.

Tabel 1. Sample data IHSG

Date	Price	Open	High	Low	Vol.	Change %
2015-01-02	5244.77	5233.80	5247.94	5230.75	3.81B	0.30%
2015-01-05	5219.99	5229.68	5233.66	5206.28	4.48B	-0.43%
2015-01-06	5169.06	5186.20	5194.80	5169.06	5.15B	-0.98%
2015-01-07	5207.12	5175.55	5207.38	5174.80	7.21B	0.74%
2015-01-08	5211.83	5218.40	5230.18	5208.99	6.92B	0.09%

Tabel 1 menampilkan sampel dari lima entri teratas dari *dataset* IHSG. Kolom *Date* merepresentasikan tanggal pencatatan data, kolom *Price* menunjukkan harga penutupan pasar pada hari yang sama, sementara kolom *Open* mencerminkan harga pembukaan pasar di hari yang sama. Kolom *High* dan *Low* masing-masing menggambarkan harga tertinggi dan terendah yang terjadi dalam satu hari perdagangan. Kolom Volume berisi informasi mengenai jumlah saham yang diperdagangkan pada tanggal tersebut, dan kolom *Change %* menunjukkan persentase perubahan harga dibandingkan dengan hari sebelumnya. Dalam penelitian ini, atribut *Price* digunakan sebagai fitur utama untuk pelatihan model karena mencerminkan harga penutupan saham, sedangkan kolom *Date* digunakan sebagai penanda waktu untuk mengurutkan data dalam analisis deret waktu.

Pra-pemrosesan Data

Langkah awal dalam proses ini adalah melakukan normalisasi data, di mana nilai asli dikonversi ke dalam rentang antara 0 hingga 1. Teknik yang diterapkan untuk normalisasi adalah *min-max normalization*, yang dihitung menggunakan rumus sebagai berikut:

$$x_{norm,i} = \frac{x_i - x_{min}}{x_{max} - x_{min}} \quad i = 1, 2, 3, \dots, t$$

dengan x_{norm} menggambarkan nilai hasil normalisasi, sementara x_{max} dan x_{min} masing-masing menunjukkan nilai maksimum dan minimum dari data.

Setelah proses normalisasi dilakukan, *dataset* kemudian dibagi menjadi dua bagian, yaitu 80% sebagai pelatihan (*training*) dan 20% sebagai pengujian (*testing*). Dari total 2509 entri data, sebanyak 2010 data awal digunakan untuk proses pelatihan, sedangkan 499 data terakhir digunakan untuk pengujian. Titik pemisahan antara data pelatihan dan pengujian ditetapkan pada tanggal 1 April 2023.

Pemilihan Hyperparameter

Sebelum proses pelatihan dan pengujian model LSTM dan GRU dilakukan, tahap pemilihan *hyperparameter* menjadi langkah penting untuk memperoleh performa model yang optimal. Penelitian ini menggunakan

pendekatan *trial and error* untuk mengevaluasi beberapa kombinasi *hyperparameter*, sebagaimana dirangkum dalam Tabel 2.

Tabel 2. Kombinasi *hyperparameter*


No	Neuron Layer 1	Neuron Layer 2	Batch Size	Epoch	Dropout	Optimizer
1	32	32	32	50	0.2	Adam
2	64	32	32	50	0.2	Adam
3	64	64	32	50	0.2	Adam
4	32	32	64	50	0.2	Adam
5	64	32	64	50	0.2	Adam
6	64	64	64	50	0.2	Adam

Training dan Testing Setiap Model

Setelah *hyperparameter* ditentukan, tahap selanjutnya adalah melakukan pelatihan model menggunakan algoritma LSTM dan GRU dengan *hyperparameter* tersebut. Pada tahap *training*, kedua model dilatih secara intensif menggunakan data *training*. Selanjutnya, proses *testing* dilakukan menggunakan data *testing* untuk menguji performa dan efektivitas model yang telah dilatih.

Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah hasil dari pengembangan arsitektur *Recurrent Neural Network* (RNN), dan pertama kali diperkenalkan oleh Hochreiter dan Schmidhuber pada tahun 1997 melalui publikasi berjudul "*Long Short-Term Memory*". LSTM dikembangkan untuk mengatasi kelemahan utama pada RNN, yaitu permasalahan *exploding gradient* dan *vanishing gradient* yang sering terjadi saat memproses data sekuensial dalam rentang waktu yang panjang. Dengan memanfaatkan *memory cell*, LSTM mampu menyimpan informasi penting dan melupakan informasi yang tidak relevan, sehingga hubungan temporal pada data dapat dipertahankan lebih baik. Kemampuannya dalam mengingat konteks waktu yang panjang menjadikan LSTM sangat cocok untuk prediksi deret waktu dan klasifikasi data sekuensial. Arsitektur LSTM secara visual dapat dilihat pada Gambar 2.



Gambar 2. Arsitektur LSTM.

Arsitektur LSTM memiliki tiga mekanisme pengendali utama yang dikenal sebagai *gate*, yaitu *forget gate* (f_t), *input gate* (i_t), *output gate* (O_t). *Forget gate* (f_t) berfungsi memutuskan informasi mana dari *cell state* yang harus dibuang atau dilupakan. *Input gate* (i_t) berperan mengontrol data baru yang akan ditambahkan dan disimpan dalam *cell state*. Sementara itu, *output gate* (O_t) menyeleksi informasi yang relevan dari *cell state* untuk dijadikan keluaran sistem. Mekanisme komputasi dalam arsitektur LSTM ini didasarkan pada penelitian Hochreiter dan Schmidhuber (1997) dengan formula matematis sebagai berikut:

$$\begin{aligned}
 f_t &= \sigma(W_{fh}[h_{t-1}], W_{fx}[x_t], b_f) \\
 i_t &= \sigma(W_{ih}[h_{t-1}], W_{ix}[x_t], b_i) \\
 \tilde{C}_t &= \tanh(W_{ch}[h_{t-1}], W_{cx}[x_t], b_c) \\
 C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t \\
 O_t &= \sigma(W_{oh}[h_{t-1}], W_{ox}[x_t], b_o) \\
 h_t &= O_t * \tanh(C_t)
 \end{aligned}$$

dimana:


x_t = input pada waktu t
 h_{t-1} = output dari waktu $t - 1$
 C_{t-1} = cell state pada waktu sebelumnya

h_t = output akhir
 W = bobot
 b = bias
 σ = fungsi aktivasi sigmoid
 \tanh = fungsi aktivasi hyperbolic tangent

Gated Recurrent Unit

Gated Recurrent Unit (GRU) merupakan salah satu varian dari *Recurrent Neural Network* (RNN) yang diperkenalkan oleh Cho et al. (2014) sebagai alternatif yang lebih sederhana dibandingkan *Long Short-Term Memory* (LSTM). Meskipun strukturnya lebih ringkas, GRU tetap efektif dalam mengatasi permasalahan *vanishing gradient* dan mampu memberikan performa prediksi yang sebanding dengan LSTM, terutama dalam tugas-tugas seperti peramalan deret waktu dan klasifikasi data sekuensial.

Berbeda dengan *Long Short-Term Memory* (LSTM) yang memiliki tiga gate utama (*forget gate*, *input gate*, dan *output gate*), *Gated Recurrent Unit* (GRU) hanya terdiri dari dua gate, yaitu *update gate* dan *reset gate* (Marwondo & Hidayah, 2022). Sederhananya arsitektur ini membuat GRU memiliki proses komputasi yang lebih ringan dan efisien dibandingkan LSTM. Dengan kompleksitas yang lebih rendah, GRU mampu mempercepat pemrosesan data, terutama pada *dataset* yang berukuran kecil, tanpa mengorbankan akurasi secara signifikan (Meriani & Rahmatulloh, 2024). Hal ini menjadikan GRU sebagai pilihan yang tepat dalam aplikasi dengan keterbatasan sumber daya atau kebutuhan proses *real-time*. Arsitektur GRU secara visual dapat dilihat pada Gambar 3.



Gambar 3. Arsitektur GRU.

Dalam arsitektur GRU, terdapat dua gate utama, yaitu *reset gate* (r) dan *update gate* (z). *Reset gate* (r) berperan dalam mengatur sejauh mana informasi dari status sebelumnya akan dihapus, sementara *update gate* (z) berfungsi untuk mengontrol proporsi informasi dari status tersembunyi sebelumnya (h_{t-1}) yang perlu dipertahankan dan diteruskan ke langkah saat ini. Proses komputasi dalam GRU mengacu pada Meriani & Rahmatulloh (2024), dengan persamaan sebagai berikut:

$$\begin{aligned}
 r &= \sigma(W_r x_t + U_r h_{t-1} + b_r) \\
 z &= \sigma(W_z x_t + U_z h_{t-1} + b_z) \\
 \tilde{h} &= \tanh(W_h x_t + r * U_h h_{t-1} + b_h) \\
 h_t &= z * h_{t-1} + (1 - z) * \tilde{h}
 \end{aligned}$$

dimana:

x_t = input pada waktu t
 h_{t-1} = output dari waktu $t - 1$
 h_t = output akhir
 \tilde{h}_t = kandidat memori
 W, U = bobot
 b = bias
 σ = fungsi aktivasi sigmoid
 \tanh = fungsi aktivasi hyperbolic tangent

Denormalisasi

Denormalisasi dilakukan untuk mengembalikan hasil prediksi yang sebelumnya berada dalam rentang 0 hingga 1 ke skala aslinya sesuai dengan nilai data sebenarnya. Proses ini menggunakan rumus berikut:

$$d = y(max - min) + min$$

di mana d adalah nilai hasil denormalisasi, y merupakan nilai prediksi dalam bentuk normalisasi, max adalah nilai maksimum dari data asli, dan min adalah nilai minimumnya.

Evaluasi Model

Dalam penelitian ini, kinerja model dievaluasi menggunakan metode *Mean Absolute Percentage Error* (MAPE). MAPE mengukur persentase kesalahan antara nilai aktual dan nilai prediksi. Rumus perhitungannya adalah sebagai berikut:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \times 100\%$$

dimana:

y_i = nilai aktual

\hat{y}_i = nilai prediksi

n = jumlah data

Menurut Lewis (1982, dalam Montañño et al., 2013), tingkat akurasi model berdasarkan nilai MAPE dapat diinterpretasikan berdasarkan beberapa kategori tertentu yang ditunjukkan pada Tabel 3 berikut:

Tabel 3. Skala MAPE

Skala MAPE	Interpretasi
< 10%	Prediksi sangat akurat
10 – 20%	Prediksi akurat
20 – 50%	Prediksi cukup akurat
> 50%	Prediksi tidak akurat


HASIL DAN PEMBAHASAN

Setelah melewati berbagai tahapan dalam metode penelitian yang telah dijabarkan sebelumnya, bab ini menyajikan hasil implementasi model prediksi menggunakan LSTM dan GRU beserta pembahasannya secara terstruktur. Pemaparan dimulai dengan visualisasi data historis IHSG, dilanjutkan dengan proses pembagian data menjadi data pelatihan (*training*) dan data pengujian (*testing*), serta pengaturan *hyperparameter* hingga diperoleh hasil prediksi dari masing-masing model.



Gambar 4. Visualisasi data historis IHSG.

Gambar 4 menyajikan visualisasi data historis harga penutupan harian IHSG selama 2509 hari perdagangan, dari tanggal 2 Januari 2015 hingga 16 Mei 2025. Grafik ini bertujuan untuk memberikan gambaran tren harga secara umum sebelum dilakukan proses pelatihan model.



Gambar 5. Pembagian data *train* dan data *test*.

Gambar 5 memperlihatkan hasil pemisahan data IHSG, di mana sebagian digunakan untuk pelatihan (*training*) dan sisanya untuk pengujian (*testing*). Data dari tanggal 2 Januari 2015 hingga 31 Maret 2023, sebanyak 2010 data, digunakan sebagai data pelatihan. Sementara itu, sebanyak 499 data dari tanggal 1 April 2023 hingga 16 Mei 2025 digunakan sebagai data pengujian. Pembagian ini dilakukan secara kronologis untuk mencerminkan skenario prediksi nyata, di mana model dipelajari dari data historis sebelum digunakan untuk memprediksi harga di masa depan.


Sebelum pelatihan model dilakukan, terlebih dahulu ditentukan beberapa kombinasi *hyperparameter* untuk model LSTM dan GRU melalui pendekatan *trial and error*. Tujuannya adalah untuk memperoleh konfigurasi terbaik yang menghasilkan performa prediksi paling optimal. Kombinasi *hyperparameter* yang diuji meliputi jumlah *neuron* pada *layer* 1 dan 2, ukuran *batch*, jumlah *epoch*, tingkat *dropout*, serta jenis *optimizer* yang digunakan, sebagaimana dirangkum pada Tabel 1.

Tabel 4 menyajikan hasil evaluasi kinerja model LSTM berdasarkan nilai *Mean Absolute Percentage Error* (MAPE) untuk setiap kombinasi *hyperparameter* yang diuji.

Tabel 4. Hasil evaluasi LSTM

No	<i>Neuron Layer</i> 1	<i>Neuron Layer</i> 2	<i>Batch Size</i>	MAPE LSTM
1	32	32	32	2.17%
2	64	32	32	2.08%
3	64	64	32	1.81%
4	32	32	64	2.96%
5	64	32	64	2.82%
6	64	64	64	2.22%

Berdasarkan Tabel 4, kombinasi *hyperparameter* terbaik untuk model LSTM diperoleh pada konfigurasi dengan 64 *neuron* pada *layer* pertama dan kedua, serta *batch size* 32, yang menghasilkan nilai MAPE sebesar 1.81%. Nilai ini merupakan yang terendah dibandingkan kombinasi lainnya, menandakan bahwa konfigurasi tersebut mampu mempelajari pola historis data IHSG dengan lebih akurat. Selain itu, terlihat bahwa peningkatan jumlah *neuron* dari 32 ke 64 secara umum menurunkan nilai MAPE, yang mengindikasikan bahwa model dengan kapasitas lebih besar cenderung memiliki performa yang lebih baik dalam menangkap kompleksitas data. Namun demikian, kombinasi dengan *batch size* 64 justru cenderung menghasilkan MAPE yang lebih tinggi, menunjukkan bahwa ukuran *batch* yang terlalu besar mungkin kurang optimal dalam konteks data ini.



Gambar 6. Perbandingan prediksi LSTM vs actual.

Gambar 6 menampilkan perbandingan antara hasil prediksi harga penutupan IHSG dari model LSTM terbaik dan data aktual selama periode pengujian, yakni dari April 2023 hingga Mei 2025. Garis dengan warna biru merepresentasikan nilai aktual, sementara garis dengan merah menunjukkan prediksi model. Secara visual, model LSTM mampu merepresentasikan pola dan tren pergerakan IHSG dengan cukup akurat, terutama pada saat terjadi lonjakan atau penurunan tajam. Hal ini mengindikasikan bahwa model berhasil mempelajari dinamika waktu dari data historis. Adapun nilai *Mean Absolute Percentage Error* (MAPE) pada konfigurasi terbaik LSTM ini adalah 1.81%, yang menunjukkan tingkat kesalahan prediksi relatif kecil terhadap data aktual.


Setelah mendapatkan hasil prediksi terbaik menggunakan model LSTM, selanjutnya dilakukan pelatihan dan pengujian model GRU dengan struktur dan metode evaluasi yang serupa. Seperti pada model LSTM, model GRU juga diuji dengan beberapa kombinasi *hyperparameter* untuk memperoleh konfigurasi yang paling optimal. Hasil evaluasi performa model GRU untuk berbagai kombinasi *hyperparameter*, yang diukur menggunakan nilai *Mean Absolute Percentage Error* (MAPE) dapat dilihat pada Tabel 5 berikut.

Tabel 5. Hasil evaluasi GRU

No	<i>Neuron Layer 1</i>	<i>Neuron Layer 2</i>	<i>Batch Size</i>	MAPE GRU
1	32	32	32	1.68%
2	64	32	32	1.73%
3	64	64	32	1.72%
4	32	32	64	1.94%
5	64	32	64	2.00%
6	64	64	64	1.74%

Berdasarkan Tabel 5, kombinasi *hyperparameter* terbaik untuk model GRU diperoleh pada konfigurasi dengan 32 *neuron* pada *layer* pertama dan kedua, serta *batch size* 32. Konfigurasi ini menghasilkan nilai MAPE sebesar 1.68%, yang merupakan nilai terendah di antara semua kombinasi yang diuji. Hasil ini menunjukkan bahwa model GRU dengan konfigurasi tersebut mampu memberikan performa prediksi yang paling akurat terhadap data historis IHSG.

Secara umum, terlihat bahwa model GRU memberikan hasil yang konsisten baik pada konfigurasi *neuron* yang lebih kecil (32) maupun yang lebih besar (64), dengan perbedaan nilai MAPE yang relatif kecil. Namun, konfigurasi dengan jumlah *neuron* yang lebih besar tidak secara otomatis memberikan performa yang lebih baik. Hal ini berbeda dari model LSTM, di mana peningkatan jumlah *neuron* cenderung menurunkan MAPE. Di sisi lain, seperti halnya pada LSTM, penggunaan *batch size* 64 pada model GRU juga cenderung menghasilkan nilai MAPE yang lebih tinggi, yang mengindikasikan bahwa *batch size* yang terlalu besar dapat mengurangi sensitivitas model terhadap variasi data dalam konteks ini.



Gambar 7. Perbandingan prediksi GRU vs aktual

Gambar 7 menampilkan hasil prediksi harga penutupan IHSG menggunakan model GRU terbaik dibandingkan dengan data aktual pada periode pengujian, yaitu dari April 2023 hingga Mei 2025. Garis dengan warna biru merepresentasikan nilai aktual, sedangkan garis dengan warna merah menunjukkan hasil prediksi dari model GRU. Secara visual, model GRU juga mampu mengikuti pola dan tren pergerakan IHSG dengan sangat baik. Pola kenaikan maupun penurunan tajam berhasil ditangkap dengan akurat oleh model, menunjukkan bahwa GRU memiliki kemampuan yang baik dalam memahami urutan dan pola temporal dari data historis. Pada konfigurasi terbaik, model GRU menghasilkan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 1.68%, yang lebih rendah dibandingkan model LSTM. Hal ini menandakan bahwa model GRU memiliki tingkat kesalahan prediksi yang lebih kecil dan performa yang lebih unggul pada data ini.

Jika dilakukan perbandingan secara langsung, model GRU terbukti memiliki performa prediksi yang lebih baik dibandingkan model LSTM. Walaupun keduanya mampu menangkap pola historis pergerakan IHSG dengan cukup akurat, GRU menunjukkan konsistensi hasil yang lebih tinggi di berbagai konfigurasi serta memiliki keunggulan dari segi efisiensi struktur, karena mampu mencapai akurasi prediksi yang optimal meskipun menggunakan jumlah *neuron* yang lebih sedikit. Oleh karena itu, dalam konteks prediksi IHSG menggunakan data historis periode 2015–2025, model GRU dapat dianggap sebagai pilihan yang lebih tepat karena memberikan hasil yang lebih akurat dan efisien.

KESIMPULAN

Penelitian ini telah berhasil mengkaji dan membandingkan kinerja dua metode *deep learning*, yaitu *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU), dalam memprediksi Indeks Harga Saham Gabungan (IHSG) berdasarkan data historis periode 2015 hingga 2025. Analisis hasil menunjukkan bahwa kedua model mampu menangkap pola temporal pergerakan IHSG dengan baik, namun model GRU secara konsisten memberikan hasil prediksi yang lebih akurat dan efisien dibandingkan LSTM, terutama dalam konteks konfigurasi model yang lebih sederhana. Meski demikian, performa GRU yang unggul ini tetap bergantung pada karakteristik *dataset* yang digunakan serta pemilihan *hyperparameter* yang optimal. Temuan ini menegaskan potensi penerapan metode kecerdasan buatan berbasis sains data dalam menyediakan indikator statistik yang lebih responsif dan adaptif terhadap dinamika ekonomi digital yang kompleks dan cepat berubah.

Dengan meningkatkan akurasi prediksi IHSG, model GRU dapat mendukung penyediaan statistik resmi yang lebih presisi dan tepat waktu, sehingga memberikan kontribusi nyata dalam memperkuat ekosistem ekonomi digital dan kreatif yang berkelanjutan. Kontribusi penelitian ini relevan dalam upaya pengembangan sistem statistik resmi yang tidak hanya mengandalkan metode tradisional, tetapi juga mengadopsi inovasi teknologi terkini, termasuk *big data* dan *artificial intelligence*. Ke depannya, integrasi model prediksi dengan data ekonomi makro dan indikator sosial lainnya diharapkan dapat lebih memperkaya kualitas dan kegunaan statistik resmi dalam mendukung kebijakan pembangunan nasional yang berbasis data dan berorientasi pada keberlanjutan.

DAFTAR PUSTAKA

- Abbas, M. A., Saputra, H. D., Octaviantara, A., Efendi, A. I., & Yasrizal. (2024). *Prediksi Harga Saham Berdasarkan Data Histori Menggunakan Algoritma LSTM, GRU & RNN*. 14(3), 195–205. <https://doi.org/10.22441/incomtech.v14i3.25132>
- Cho, K., van Merriënboer, B., Gulcehre, C., Bougares, F., Schwenk, H., Bahdanau, D., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation*. <https://doi.org/10.48550/arXiv.1406.1078>
- Esli Silalahi, R. S. (2021). *PENGARUH FAKTOR MAKRO EKONOMI TERHADAP PERGERAKAN INDEKS HARGA SAHAM GABUNGAN (IHSG) DI BURSA EFEK INDONESIA PERIODE 2017-2020*. 7(2), 139–152. <https://doi.org/10.54367/jrak.v7i2.1361>
- Hariyanti, I., Putra, V. H. C., & Raharja, A. R. (2025). *PREDIKSI HARGA SAHAM BBKA MENGGUNAKAN METODE LONG SHORT-TERM MEMORY DAN GATED RECURRENT UNIT*. 7(1), 11–18. <https://ejurnal.ars.ac.id/index.php/jti/article/view/1901>
- Hochreiter, Sepp Schmidhuber, J. (1997). *Long Short-Term Memory*. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Jannah, M., Rahmawati, J., Amiroh, M., & Azmi, Z. (2024). *Return Saham : Analisis Faktor Yang Mempengaruhinya Pada Perusahaan Manufaktur Di Bursa Efek Indonesia*. 2(1), 35–42.
- Lara-Bentez, P., Carranza-Garcia, M., & Riquelme, J. C. (2021). *An Experimental Review on Deep learning Architectures for Time series Forecasting **. 31(3), 1–25. <https://doi.org/10.1142/S0129065721300011>
- Liu, J. (2024). *Navigating the Financial Landscape : The Power and Limitations of the ARIMA Model*. 88, 747–752.
- Marwondo, & Hidayah, T. (2022). *Perbandingan Algoritma Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU) untuk Prediksi Harga Emas Dunia*. 22(02).
- Meriani, A. P., & Rahmatulloh, A. (2024). *PERBANDINGAN GATED RECURRENT UNIT (GRU) DAN ALGORITMA LONG SHORT TERM MEMORY (LSTM) LINEAR REFRESSION DALAM PREDIKSI HARGA EMAS MENGGUNAKAN MODEL TIME SERIES*. July. <https://doi.org/10.23960/jitet.v12i1.3808>
- Montaño, J. J., Palmer Pol, A., Sesé Abad, A., & Cajal Blasco, B. (2013). *Using the R-MAPE index as a resistant measure of forecast accuracy*. 25(4), 500–506. <https://doi.org/10.7334/psicothema2013.23>
- Putro, S., Hermawan, A., & Avianto, D. (2023). *PREDIKSI HARGA EMAS MENGGUNAKAN ALGORITMA LONG SHORT-TERM MEMORY (LSTM) DAN LINEAR REGRESSION (LR)*. 9(2).
- Rohyati, Rokhmah, F. P. N., Syazeedah, H. N. U., Fitriyaningrum, R. I., Ramadhan, G., & Syahwildan, M. (2024). *Tantangan dan Peluang Pasar Modal Indonesia dalam Meningkatkan Minat Investasi di Era Digital*. 3(1), 909–918.
- Septani, A. V., Afendi, F. M., & Kurnia, A. (2025). *Perbandingan Metode GARCH, LSTM, GRU, dan CNN pada Peramalan Volatilitas Kurs*. 22(1), 149–169.
- Shiri, F. M., Perumal, T., & Mustapha, N. (2024). *A Comprehensive Overview and Comparative Analysis on Deep learning Models. ML*. <https://doi.org/10.32604/jai.2024.054314>
- Sunendar, N., Putro, H. P., & Hesnananda, R. (2025). *Prediksi Penjualan Aerosol Menggunakan Algoritma ARIMA, LSTM Dan GRU*. 4(1), 113–126. <https://doi.org/10.55123/insologi.v4i1.4868>
- Waqas, M., & Humphries, U. W. (2024). *A Critical Review of RNN and LSTM Variants in Hydrological Time series Predictions MethodsX A critical review of RNN and LSTM variants in hydrological time series predictions*. *MethodsX*, 13(September), 102946. <https://doi.org/10.1016/j.mex.2024.102946>